گزارش انجام تسک آزمایشی - تحلیل شبکه و داده‌های پروفایل (مؤسسه سایبریان)

تهیه‌کننده: سعید سعادتی‌گرو

تاریخ: ۱۴۰۵/۰۸/۲۲

مقدمه

با سلام و احترام،

پیرو درخواست شما مبنی بر انجام تسک آزمایشی، پروژه‌ای تحت عنوان **LinkedIn Network Analyzer** با زبان پایتون پیاده‌سازی شد. تمامی الزامات خواسته‌شده (شامل استخراج داده‌ها، تحلیل مبتنی بر گراف و ML و مستندسازی) طبق استانداردهای مهندسی نرم‌افزار انجام گرفته است. در ادامه خلاصه‌ای از اقدامات و منطق پیاده‌سازی ارائه می‌شود.

۱. روش تهیه و استخراج داده‌ها (Data Extraction)

برای رعایت اصول اخلاقی و جلوگیری از هرگونه مشکل حقوقی (مانند Scraping)، از داده‌های کاملاً **سینتتیک (Synthetic)** استفاده شده است. یک اسکریپت پایتون (generate_sample_data.py) طراحی شده که دقیقاً ۱۰ پروفایل ساختگی مربوط به یک سازمان فرضی (Nimbus Analytics) را تولید می‌کند.

داده‌ها شامل: اطلاعات پایه، سوابق شغلی، تحصیلی، مهارت‌ها (با غلط‌های املایی عمدی برای تست نرمال‌سازی)، علایق و تعاملات اخیر (Activity) است. داده‌های خام در قالب JSON ذخیره شده و سپس با استفاده از کتابخانه Pandas به جداول تمیز و ساختاریافته (DataFrames) تبدیل می‌شوند.


```json
{
  "profiles": [
    {
      "profile_id": "p01",
      "profile_url": "https://www.linkedin.com/in/example-person-01",
      "full_name": "Elena Markovic",
      "headline": "CTO at Nimbus Analytics",
      "location": "Berlin, Germany",
      "summary": "Engineering leader focused on scalable platforms and applied AI.",
      "current_title": "Chief Technology Officer",
      "current_company": "Nimbus Analytics",
      "total_experience_months": 139,
      "num_skills": 6,
      "interests": "AI Strategy; Engineering Culture; Open Source",
      "num_activities": 3
    },
    {
      "profile_id": "p02",
      "profile_url": "https://www.linkedin.com/in/example-person-02",
      "full_name": "Daniel Reyes",
      "headline": "Head of AI at Nimbus Analytics",
      "location": "Madrid, Spain",
      "summary": "Leads the AI team; NLP and MLOps practitioner.",
      "current_title": "Head of AI",
      "current_company": "Nimbus Analytics",
      "total_experience_months": 109,
      "num_skills": 6,
      "interests": "Language Models; Mentoring; Running",
      "num_activities": 5
    },
    {
      "profile_id": "p03",
      "profile_url": "https://www.linkedin.com/in/example-person-03",
      "full_name": "Sofia Lindqvist",
      "headline": "ML Engineer | Computer Vision",
      "location": "Stockholm, Sweden",
      "summary": "Builds and ships computer vision models to production.",
      "current_title": "ML Engineer",
      "current_company": "Nimbus Analytics",
      "total_experience_months": 92,
      "num_skills": 6,
      "interests": "Computer Vision; Photography; Hiking",
      "num_activities": 4
    },
```

۲. منطق تحلیل (ML Analysis & Graph)

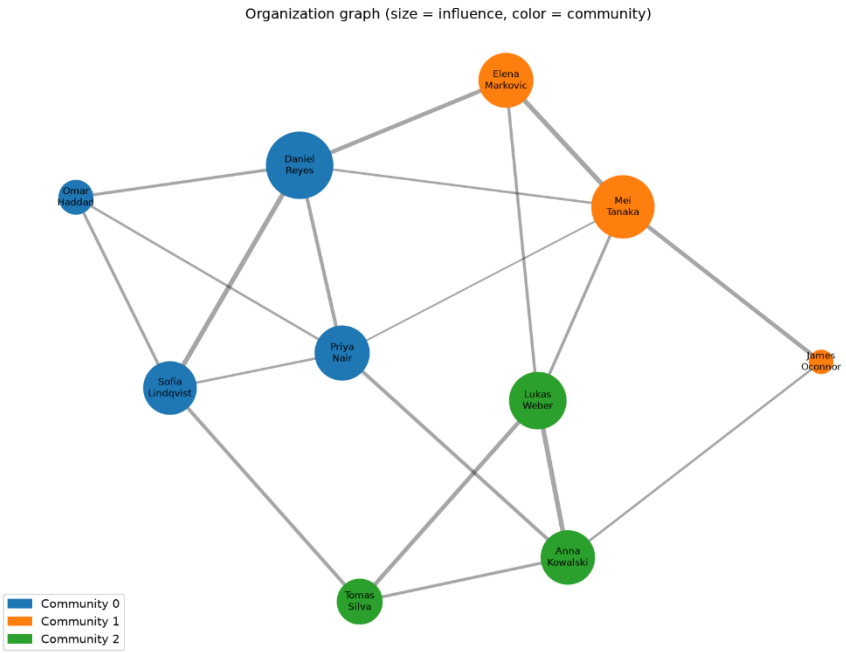
تحلیل در دو بخش اصلی انجام شده است:

- **تحلیل گراف (NetworkX)**: یک گراف وزن‌دار از ارتباطات افراد ساخته شده است. وزن یال‌ها بر اساس نوع ارتباط (مدیر-کارمند، همکار، منتور) و تعاملات (لایک، کامنت، ری‌پست) تعیین شده است. سپس شاخص‌های مرکزیت (Centrality) مانند *Betweenness* و *Degree* برای شناسایی افراد کلیدی و پل‌های ارتباطی محاسبه شده و الگوریتم‌های تشخیص انجمن (Community Detection) برای یافتن خوشه‌های کاری اجرا شده است.
- **تحلیل یادگیری ماشین (Scikit-learn)**: برای خوشه‌بندی مهارت‌ها، از روش TF-IDF برای تبدیل مهارت‌ها به بردار و از الگوریتم KMeans برای خوشه‌بندی افراد استفاده شده است. تعداد خوشه‌های بهینه (k) به صورت خودکار با معیار Silhouette Score انتخاب می‌شود.

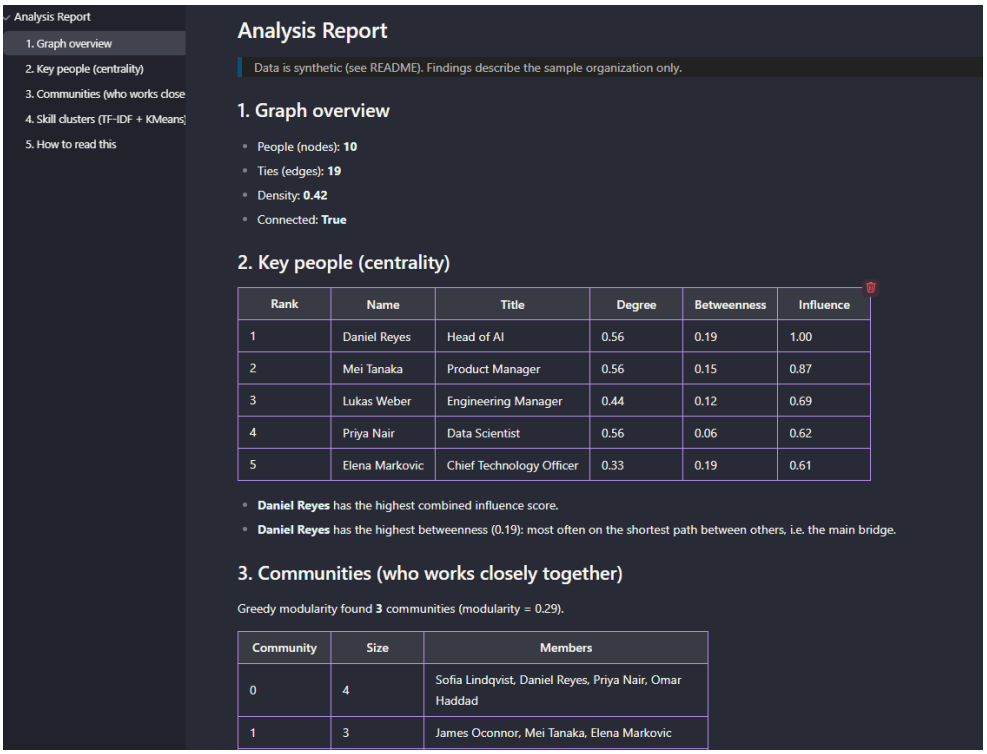
۳. خروجی‌های پروژه (Outputs)

تمامی خروجی‌ها در ریپازیتوری گیت‌هاب (که لینک آن در ایمیل قرار دارد) موجود است:
https://github.com/saeidsaadatigero/linkedin-network-analyzer

- **داده‌های تمیزشده:** فایل‌های CSV و JSON
- **خروجی گراف:** فایل تصویری graph.png (اندازه نودها بر اساس نفوذ، رنگ‌ها بر اساس جامعه کاری) و فایل graph.json.



- **گزارش تحلیلی**: فایل report.md شامل معرفی افراد کلیدی، خوشه‌های ارتباطی و مهارتی.



Analysis Report

1. Graph overview
2. Key people (centrality)
3. Communities (who works close
4. Skill clusters (TF-IDF + KMeans
5. How to read this

Analysis Report

Data is synthetic (see README). Findings describe the sample organization only.

1. Graph overview

- People (nodes): **10**
- Ties (edges): **19**
- Density: **0.42**
- Connected: **True**

2. Key people (centrality)

Rank	Name	Title	Degree	Betweenness	Influence
1	Daniel Reyes	Head of AI	0.56	0.19	1.00
2	Mei Tanaka	Product Manager	0.56	0.15	0.87
3	Lukas Weber	Engineering Manager	0.44	0.12	0.69
4	Priya Nair	Data Scientist	0.56	0.06	0.62
5	Elena Markovic	Chief Technology Officer	0.33	0.19	0.61

- **Daniel Reyes** has the highest combined influence score.
- **Daniel Reyes** has the highest betweenness (0.19): most often on the shortest path between others, i.e. the main bridge.

3. Communities (who works closely together)

Greedy modularity found **3** communities (modularity = 0.29).

Community	Size	Members
0	4	Sofia Lindqvist, Daniel Reyes, Priya Nair, Omar Haddad
1	3	James Oconnor, Mei Tanaka, Elena Markovic

۴. پاسخ به سوالات مقیاس‌پذیری (Scalability)

- **مدیریت استخراج آنلاین (Headers & Rate Limiting)**: در صورت استفاده از دیتای واقعی، از هدرهای استاندارد و User-Agent معتبر استفاده می‌شد. همچنین برای جلوگیری از بلاک شدن، از الگوریتم‌های Rate Limiting (مانند Token Bucket) و مدیریت خطای 429 Too Many Requests با روش‌های Backoff استفاده می‌شد.

- **پردازش با صف (Queue)**: برای حجم بالای داده، معماری به صورت توزیع‌شده پیاده‌سازی می‌شد. از Redis Streams یا Kafka برای صف‌بندی استفاده می‌شد تا مراحل استخراج (Fetch)، نرمال‌سازی و تحلیل به صورت مستقل و مقیاس‌پذیر انجام شوند.

- **ذخیره‌سازی در مقیاس بزرگ**: داده‌های خام در Object Storage (مانند S3) ذخیره می‌شوند. داده‌های پردازش‌شده به فرمت ستونی Parquet تبدیل شده و برای تحلیل‌های سریع در ابزارهایی مثل DuckDB یا Spark بارگذاری می‌شوند. برای کوئری‌های سریع روی گراف، از پایگاه‌داده‌های گرافی مانند Neo4j استفاده می‌شد.

جمع‌بندی

این پروژه با رعایت اصول Clean Code، طراحی ماژولار (Pipeline-based) و تست‌های خودکار (pytest) پیاده‌سازی شده است.

از توجه شما سپاسگزارم و آماده ارائه توضیحات تکمیلی هستم.